Universidad de Costa Rica

Escuela de Computación e Informática

Análisis de grandes volúmenes de datos

CI-0163

Grupo 01

Laboratorio 2
OpenRefine

Profesor: Jonathan Esquivel

Elaborado por:

Nathalia Maria Chaves Oviedo C22195

Gael Alpízar Alfaro C20270

2026

Pasos realizados

1. Carga del dataset en OpenRefine

Se inició el proceso importando el dataset “Cafe Sales - Dirty Data for Cleaning Training” en la herramienta OpenRefine, ejecutada en su entorno web local. Durante esta etapa, se verificó que los datos fueron cargados correctamente, identificando un total de diez columnas y aproximadamente diez mil registros.

2. Exploración inicial de los datos

Posteriormente, se realizó una exploración general del dataset con el objetivo de identificar posibles problemas de calidad de datos. En esta fase se detectaron:

- Valores faltantes (celdas en blanco)
- Valores inconsistentes (como *UNKNOWN*, *NULL* y *ERROR*)
- Posibles errores de formato en fechas y valores numéricos

Esta exploración permitió determinar qué columnas requerían procesos de limpieza, destacando principalmente: Payment Method, Location, Total Spent, Transaction Date y Price Per Unit.

3. Identificación de valores vacíos mediante Facets

Para identificar registros con datos incompletos, se utilizó la funcionalidad de Facets en OpenRefine.

Se aplicó la opción:

- *Facet, Customized Facets, Facet by Blank*

Esto generó una clasificación binaria:

- True: filas con valores vacíos
- False: filas con datos completos

Este proceso permitió aislar y analizar específicamente los registros con información faltante, como se observa a continuación:

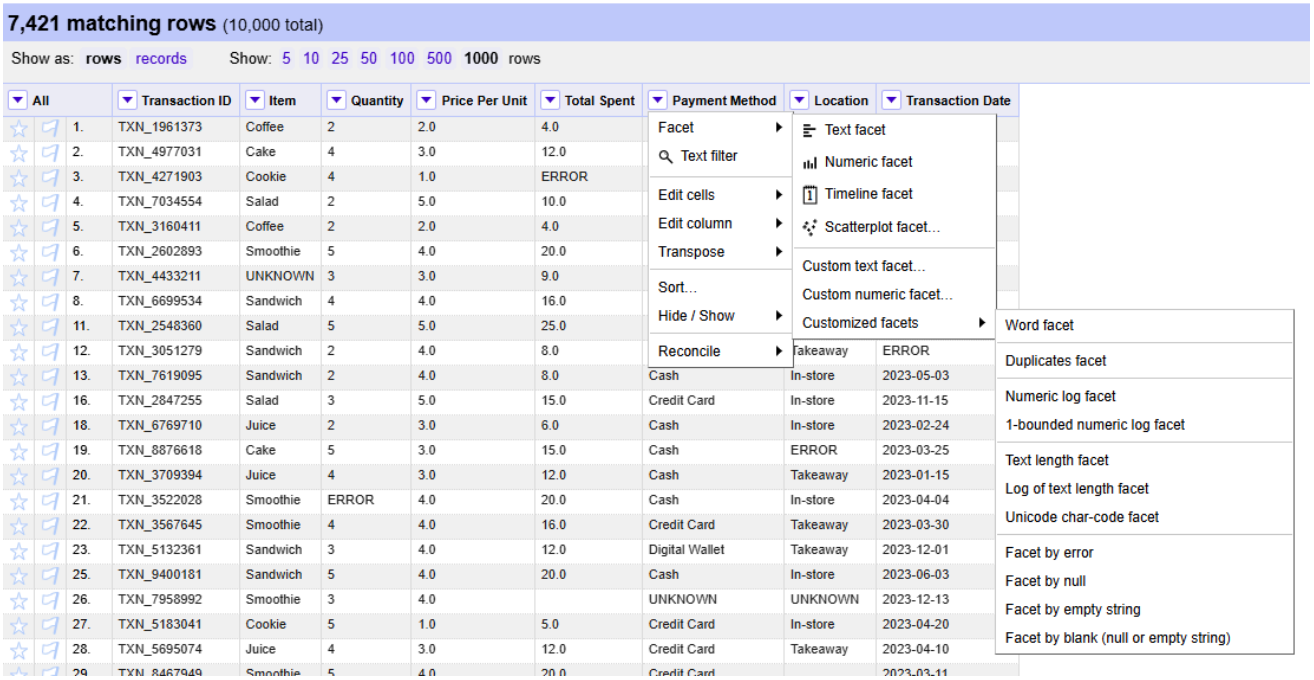

4. Filtrado de valores inconsistentes

Seguidamente, se aplicaron filtros sobre las diferentes columnas con inconsistencias para identificar valores anómalos como:

- *UNKNOWN*
- *NULL*
- *ERROR*

Esto se realizó mediante:

- *Facet, Text Facet*

Una vez identificados estos valores, se procedió a analizarlos individualmente para determinar si debían ser eliminados, corregidos o transformados.

5. Limpieza y corrección de datos mediante transformaciones y uso de funciones en GREL para transformaciones más completas

Con base en los hallazgos anteriores, se aplicaron transformaciones para mejorar la calidad del dataset. Entre las principales acciones realizadas se encuentran:

- Reemplazo del valor *UNKNOWN* por valores vacíos o estandarizados
- Creación de una nueva columna *VOLUME*

Estas transformaciones se realizaron utilizando funciones integradas de OpenRefine y expresiones avanzadas en GREL.

Reemplazo de Unknown

Edit facet's Expression based on Column Item

Expression Language General Refine Expression Language (GREL)

```
if(value == "UNKNOWN", "No item", "Has item")
```

No syntax error.

Preview History Starred Help

row	value	if(value == "UNKNOWN", "No ite ...
1.	Coffee	Has item
2.	Cake	Has item
3.	Cookie	Has item
4.	Salad	Has item
5.	Coffee	Has item
6.	Smoothie	Has item

OK Cancel

Item change invert reset

2 choices Sort by: name count

Has tem 9323 exclude

No item 344

Facet by choice counts

Creación de nueva columna Volume

Add column based on column Quantity

New column name

On error: set to blank / store error / copy value from original column

Expression — Language: General Refine Expression Language (GREL)

```
if(isNumeric(value),
  if(toNumber(value) >= 5, "Big",
    if(toNumber(value) >= 3, "Medium", "Small")
  ),
  null
)
```

No syntax error.

Preview | History | Starred | Help

141.	3	Medium
143.	1	Small
144.	1	Small
145.	2	Small
146.	5	Big
148.	4	Medium
150.	2	Small

OK | Cancel

Show as: **rows** records Show: 5 10 25 50 100 500 **1000** rows

All	Transaction ID	Item	Quantity	Volume	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
1.	TXN_1961373	Coffee	2	Small	2.0	4.0	Credit Card	Takeaway	2023-09-08
2.	TXN_4977031	Cake	4	Medium	3.0	12.0	Cash	In-store	2023-05-16
5.	TXN_3160411	Coffee	2	Small	2.0	4.0	Digital Wallet	In-store	2023-06-11
11.	TXN_2548360	Salad	5	Big	5.0	25.0	Cash	Takeaway	2023-11-07
13.	TXN_7619095	Sandwich	2	Small	4.0	8.0	Cash	In-store	2023-05-03
16.	TXN_2847255	Salad	3	Medium	5.0	15.0	Credit Card	In-store	2023-11-15
18.	TXN_6769710	Juice	2	Small	3.0	6.0	Cash	In-store	2023-02-24
20.	TXN_3709394	Juice	4	Medium	3.0	12.0	Cash	Takeaway	2023-01-15
22.	TXN_3567645	Smoothie	4	Medium	4.0	16.0	Credit Card	Takeaway	2023-03-30
23.	TXN_5132361	Sandwich	3	Medium	4.0	12.0	Digital Wallet	Takeaway	2023-12-01
25.	TXN_9400181	Sandwich	5	Big	4.0	20.0	Cash	In-store	2023-06-03
27.	TXN_5183041	Cookie	5	Big	1.0	5.0	Credit Card	In-store	2023-04-20
28.	TXN_5695074	Juice	4	Medium	3.0	12.0	Credit Card	Takeaway	2023-04-10
35.	TXN_8853997	Smoothie	2	Small	4.0	8.0	Digital Wallet	Takeaway	2023-10-09
38.	TXN_1080432	Salad	2	Small	5.0	10.0	Credit Card	In-store	2023-04-29
47.	TXN_8078640	Juice	4	Medium	3.0	12.0	Digital Wallet	In-store	2023-11-03
55.	TXN_8614868	Smoothie	5	Big	4.0	20.0	Digital Wallet	Takeaway	2023-12-05
59.	TXN_6421134	Sandwich	4	Medium	4.0	16.0	Cash	Takeaway	2023-11-03
68.	TXN_3068204	Cookie	1	Small	1.0	1.0	Credit Card	Takeaway	2023-10-03
71.	TXN_2621580	Tea	2	Small	1.5	3.0	Cash	In-store	2023-03-22
72.	TXN_4726376	Cake	2	Small	3.0	6.0	Credit Card	In-store	2023-01-31
76.	TXN_6420335	Coffee	1	Small	2.0	2.0	Cash	Takeaway	2023-07-16
80.	TXN_3829165	Juice	4	Medium	3.0	12.0	Cash	In-store	2023-06-15
81.	TXN_3748616	Coffee	2	Small	2.0	4.0	Credit Card	In-store	2023-12-09
84.	TXN_5266394	Cake	3	Medium	3.0	9.0	Cash	In-store	2023-10-28
91.	TXN_8976658	Tea	2	Small	1.5	3.0	Credit Card	In-store	2023-08-16
97.	TXN_5220895	Salad	5	Big	5.0	25.0	Cash	In-store	2023-06-10
98.	TXN_3085509	Coffee	4	Medium	2.0	8.0	Digital Wallet	In-store	2023-04-15
99.	TXN_9999113	Juice	4	Medium	3.0	12.0	Cash	Takeaway	2023-05-27
100.	TXN_8779771	Coffee	4	Medium	2.0	8.0	Cash	In-store	2023-07-25
103.	TXN_3808639	Juice	2	Small	3.0	6.0	Digital Wallet	Takeaway	2023-12-15
109.	TXN_4358673	Cookie	5	Big	1.0	5.0	Digital Wallet	Takeaway	2023-12-28
120.	TXN_4368416	Salad	2	Small	5.0	10.0	Credit Card	Takeaway	2023-02-24
124.	TXN_6258471	Coffee	5	Big	2.0	10.0	Digital Wallet	In-store	2023-09-23
126.	TXN_4685453	Tea	4	Medium	1.5	6.0	Cash	In-store	2023-09-14
128.	TXN_9096052	Smoothie	4	Medium	4.0	16.0	Credit Card	Takeaway	2023-12-28
129.	TXN_5916991	Juice	2	Small	3.0	6.0	Digital Wallet	Takeaway	2023-02-06
130.	TXN_3407169	Sandwich	2	Small	4.0	8.0	Cash	In-store	2023-03-11

6. Clustering

Se utilizó la funcionalidad de clustering en OpenRefine para identificar y unificar valores similares en columnas categóricas, como Payment Method. Se detectaron inconsistencias como diferencias en mayúsculas y variaciones en la escritura de un mismo valor.

Inicialmente, se aplicó el método key collision (fingerprint) para agrupar valores equivalentes.

Finalmente, se unificaron los valores mediante la opción Merge selected & re-cluster, permitiendo una limpieza iterativa hasta lograr una representación uniforme de los datos.

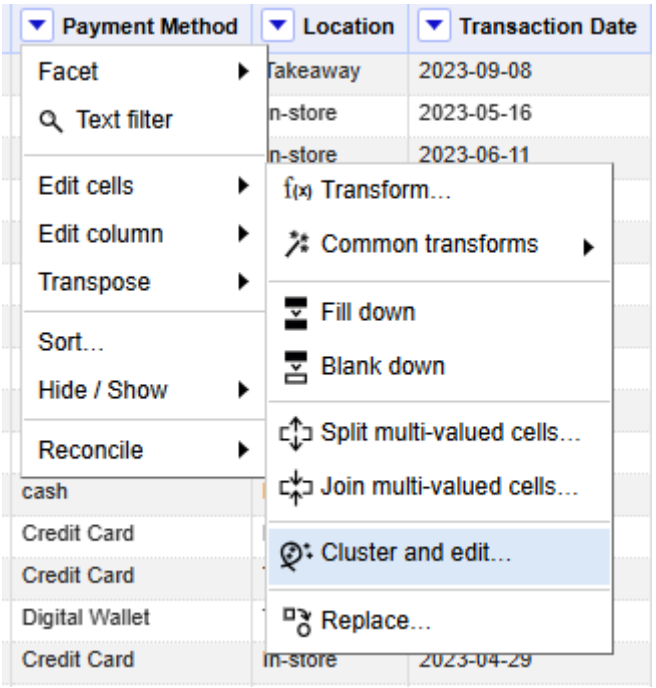

Cluster and edit column "Payment Method"

Find groups of different cell values that might be other representations of the same thing. For example, "New York" and "new york" likely refer to the same concept and just differ by capitalization, and "Gödel" and "Godel" probably refer to the same person. Find out more...

Method Key collision Keying function Fingerprint Manage clustering fuctions

Auto-update 1 cluster found

Merge?	Values in cluster	New cell value	Cluster size	Row count
☑	☑ Cash (1055 rows) ☑ cash	Cash	2	1056

Select all Deselect all Export clusters **Merge selected & re-cluster** Merge selected & Close Close

3,204 matching rows (10,000 total)

Show as: **rows** records Show: 5 10 25 50 100 500 **1000** rows

All	Transaction ID	Item	Quantity	Volume	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
1.	TXN_1961373	Coffee	2	Small	2.0	4.0	Credit Card	Takeaway	2023-09-08
2.	TXN_4977031	Cake	4	Medium	3.0	12.0	Cash	In-store	2023-05-16
5.	TXN_3160411	Coffee	2	Small	2.0	4.0	Digital Wallet	In-store	2023-06-11
11.	TXN_2548360	Salad	5	Big	5.0	25.0	Cash	Takeaway	2023-11-07
13.	TXN_7619095	Sandwich	2	Small	4.0	8.0	Cash	In-store	2023-05-03
16.	TXN_2847255	Salad	3	Medium	5.0	15.0	Credit Card	In-store	2023-11-15
18.	TXN_6769710	Juice	2	Small	3.0	6.0	Cash	In-store	2023-02-24
20.	TXN_3709394	Juice	4	Medium	3.0	12.0	Cash	Takeaway	2023-01-15
22.	TXN_3567645	Smoothie	4	Medium	4.0	16.0	Credit Card	Takeaway	2023-03-30
23.	TXN_5132361	Sandwich	3	Medium	4.0	12.0	Digital Wallet	Takeaway	2023-12-01
25.	TXN_9400181	Sandwich	5	Big	4.0	20.0	Cash	In-store	2023-06-03
27.	TXN_5183041	Cookie	5	Big	1.0	5.0	Credit Card	In-store	2023-04-20
28.	TXN_5695074	Juice	4	Medium	3.0	12.0	Credit Card	Takeaway	2023-04-10
35.	TXN_8853997	Smoothie	2	Small	4.0	8.0	Digital Wallet	Takeaway	2023-10-09
38.	TXN_1080432	Salad	2	Small	5.0	10.0	Credit Card	In-store	2023-04-29
47.	TXN_8078640	Juice	4	Medium	3.0	12.0	Digital Wallet	In-store	2023-11-03
55.	TXN_8614868	Smoothie	5	Big	4.0	20.0	Digital Wallet	Takeaway	2023-12-05
59.	TXN_6421134	Sandwich	4	Medium	4.0	16.0	Cash	Takeaway	2023-11-03
68.	TXN_3068204	Cookie	1	Small	1.0	1.0	Credit Card	Takeaway	2023-10-03
71.	TXN_2621580	Tea	2	Small	1.5	3.0	Cash	In-store	2023-03-22